

基于大模型的医疗质控应用系统构建

吴宏¹ 胡军¹ 陈尔真² 董晨杰² 李建华³ 叶琪³

(¹上海市卫生健康委员会 上海 200125 ²上海市医疗质量控制管理事务中心 上海 20040 ³华东理工大学 上海 200237)

〔摘要〕 **目的/意义** 本研究旨在开发基于大语言模型的医疗质量控制系统，以提升质控的自动化水平与准确性。**方法/过程** 本系统通过获取高质量医学数据（包括通用医疗数据和质控相关数据）对 PULSE 模型进行微调，并结合自动化指标计算与检索增强生成技术，高效执行复杂质控任务。**结果/结论** 本系统在自动化计算与推理准确性上实现了显著提升，其准确度达到了 93.31%，超越了基座大模型和常见推理方法，具有重要的医疗质量控制应用价值。

〔关键词〕 大模型; 指令微调; 医疗质控

Construction of a Medical Quality Control Application System Based on Large Language Models
WU Hong¹, HU Jun¹, CHEN Erzhen², DONG Chenjie², LI Jianhua², YE Qi²

¹Shanghai Municipal Health Commission, Shanghai 200125, China; ²Shanghai Medical Quality Control Management Center, Shanghai, China; ³East China University of Science and Technology, Shanghai 200237, China

〔Abstract〕 **Purpose/Significance** This study aims to develop a medical quality control system based on large language models (LLMs) to enhance the automation and accuracy of quality control processes. **Method/Process** The system utilizes a diverse set of high-quality medical data, including general medical data and quality control-related data, to fine tune the PULSE model. Automated indicator calculation and retrieval-augmented generation (RAG) techniques are then employed to enable the system to efficiently perform complex quality control tasks. **Result/Conclusion** The system demonstrates significant improvements in automated computation and inference accuracy, achieving an accuracy of 93.31%. It outperforms baseline language models and common inference methods, offering significant implications for medical quality control.

〔Keywords〕 Large Language Models, Instruction Fine-Tuning, Medical Quality Control

bmr.202503.00004V1

〔收稿日期〕 2025-01-22

〔作者简介〕 吴宏，上海市卫生健康委员会医政医管处处长，发表论文 30 余篇；通讯作者 叶琪，讲师。

〔基金项目〕 国家重点研发计划（项目编号：2023YFF1204904）

1. 引言

医疗质量直接关系到人民群众的健康权益和对医疗服务的切身感受。为加强医疗质量管理，规范医疗服务行为，保障医疗安全，国家卫生健康委出台了《医疗质量管理办法》(2016年9月25日国家卫生和计划生育委员会令第10号公布)。通过建立全面的医疗质量管理指标体系^[1]，卫生计生行政部门或医疗质控组织能够在医疗服务能力、质量与安全、运行效率以及综合管理等方面实现精准的质量控制^{[2][3]}，并为医院管理和医疗质量的持续改进提供可靠的数据支持。

以往的质控指标主要通过各医院的各条线工作人员填报上传指标结果（或者分子、分母结果），这种依赖于主观填报的方式难以全面、准确地反映各医院的真实医疗质量。即使到了当下，因为多数质控指标是对过程性医疗质量进行评价，无法通过医嘱、病案首页、收费数据等结构性数据取到，因此仍然有较大比例过程性质控指标依赖于人工填报。鉴于大模型（Large Language Model, LLM）^{[4][5][6]}在自然语言处理方面的优势及其对数据标注需求的减少，如果将脱敏后的电子病历信息和指标计算要求输入LLM，由其自动生成质控指标统计结果，将会快速且精准地实现医疗过程的自动化质控，极大减少管理成本。因此，本文提出了一种基于大模型的医疗质控应用系统（[简称为“医管大模型系统”](#)），通过对基座大模型的指令微调，提升其医疗质量管理知识理解能力，进而实现质控指标的自动化计算，并确保该计算过程具有较高的置信度。

2. 相关研究

2.1 医疗大模型

自然语言文本在日常生活中无处不在，大语言模型依托大规模文本数据迅猛发展，代表性模型包括如OpenAI公司的ChatGPT系列^[10]、Google公司的Gemini^[11]、Meta公司的LLaMA^[12]，以及国内的包括如阿里的通义千问^[13]、百度的文心一言、上海人工智能实验室的PULSE等。尽管医学领域同样积累了丰富的医学文献和临床数据，但其高专业性及中文语法特性，增加了预训练语言模型（Pre-trained Language Model, PLM）处理医学数据的复杂性。

针对上述挑战，学术界、企业界和医疗界相继提出了一系列基于中文医学文本的大模型，以优化医学数据处理的效果。针对标注人员医学知识不足的问题，华佗模型^[14]使用医生提供的真实数据进行微调，同时辅以ChatGPT生成的蒸馏数据进行优化。扁鹊模型^[15]在训练时采用自建的多轮对话数据集，从而模拟医生通过多次交流了解病情的现实情境。明医模型^[16]通过混合专家技术（Mixture of Experts, MoE）克

服了传统医学大模型仅在特定任务上表现较好的局限性，使其能够适应复杂多样的医学任务，如医学自然语言处理和医师资格考试。PULSE模型使用约四百万个中文医学领域和通用领域的指令微调数据进行进一步调优，它可以支持医学领域的各种自然语言处理任务，包括健康教育、医师考试问题、报告解读、医疗记录结构化以及模拟诊断和治疗等。

虽然当前LLM在医学领域的应用已涵盖医疗命名实体识别、医学因果关系抽取等任务，[但其在医疗质控领域的应用仍显不足。](#)

2.2 医疗质控

基于传统方法，多数医院的质控仍主要依赖人工抽查。然而，面对庞大的电子病历数据^{[18][19]}，难以确保所抽取样本能够充分反映整体情况，从而导致数据偏差。电子病历以文本形式存储，而LLM依赖大规模自然语言文本（如互联网数据）进行训练。在解决数据偏差问题上，LLM展现出潜在的应用前景，已有部分医院尝试将其应用于医疗质控实践。

吉林大学第二医院信息中心构建了一个智能医疗质控系统，通过预设质控规则及知识图谱模型匹配标准，实现质量控制的自动识别^[20]。南京鼓楼医院开发了一种单病种质控管理平台^[21]，运用自然语言处理技术将非结构化数据转化为结构化数据，并结合数据仓库技术进行数据抽取与清洗，实现了单病种质量控制的自动化。

虽然上述方法主要利用LLM进行数据处理，但对医疗质控指标计算的应用尚处于初步阶段。本文旨在提高LLM在指标计算中的应用频率，以最大限度地发挥其潜能。

3. 基于大模型的医疗质控应用系统框架

本系统由三大核心模块组成，包括：数据获取与处理、指令微调与指标自动化计算。首先，数据获取与处理模块负责采集并处理高质量的医学数据，这些数据为指令微调模块提供基础。随后，指令微调模块在多样化数据的支持下，结合精心设计的指令来优化大模型性能。最后，指标自动化计算模块通过高效的计算方法，实现对关键指标的精确评估。

3.1 数据获取与处理

由于通用大模型在训练过程中缺乏大量的专业性较强的医疗数据，将其直接应用于各类医疗领域时表现欠佳。因此，获取高质量的医学数据成为提升模型性能的关键。指令微调的数据主要来自于临床指南、专家共识、以及专业质量控制指标等文本，内容覆盖广泛，包含中/西医术语、通用领域语料、以及各临床专业的临床指

南等。为进一步提升医学数据的质量，本文对数据进行了多步处理：首先，对数据进行了去重操作，以减少冗余信息的影响；接着，将文本进行分割，以防止长文本输入造成的潜在遗忘问题；最后，删除了无关或噪声信息，以确保模型能够更精准地理解相关领域内容。通过上述步骤，本文所提方法显著提高了数据的质量与有效性，为模型的优化提供了坚实的基础。

3.2 大模型指令微调

构建指令微调^{[22][23][24]}的数据时，本文首先设计任务模板，模板中的指令部分用于清晰描述任务的具体内容；然后使用专家标注的脱敏电子病历数据与模板的输入、输出部分进行匹配。随后，采用人工编写和模型协作的方式，扩展和构建多样化的任务指令，涵盖通用指令数据、基础医疗指令数据、以及质量控制数据等不同类型。为了防止医学模型在微调过程中产生遗忘，本文又采用了迭代微调方法：每轮微调均使用一组数据，同时混合少量前一组数据，

最后一轮迭代时整合所有数据。通过这一迭代策略，最终获得了性能稳定的模型。

3.3 基于 auto-prompt 的质控指标计算

各级卫生行政部门、质控中心目前通过单病种管理模式对医疗质量进行监控。每个单病种对应多个质控指标，而每个指标可能包含多个具体任务。若依赖人工编写提示词（prompt）的方式，既耗时又费力，自动化的提示生成（auto-prompt）方法因此显得尤为关键。

据此，本文设计了一套 auto-prompt 方法：首先，该方法由大模型对单病种指标进行任务分解，将复杂指标细化为多个细粒度任务；接着，通过知识召回技术，从医学知识库中提取与这些任务相关的核心信息；随后，整合所有相关知识，让大模型生成能够准确描述该指标的 prompt。最后，将生成的 prompt 与电子病历相关文本输入模型，即可自动判断该病历是否符合相应单病种指标的要求。




图 1 基于大模型的医疗质控应用系统

4. 基于大模型的医疗质控应用系统的关键技术

4.1 基于医疗质控的大语言模型指令微调

考虑到国内医院对应用成本和大模型性能的要求，本系统采用现有的 PULSE 基座模型，对其进行指令微调。这一方案兼顾了成本效益与模型优化效果，为医疗质控系统提供了更具可操作性和精准度的解决方案。

4.1.1 医疗质控指令的构建

在构建医疗质控指标计算任务指令数据集时，本系统特别注重引入多样化的任务指令提示，旨在确保模型能够在各种医疗场景下准确理解并执行质控指标计算任务，从而提升模型的泛化能力及其在真实世界中的应用有效性。每条任务指令由两个核心部分组成：任务描述和占位符。任务描述通过清晰的文本形式，明确传达需要完成的具体任务，指导模型的执行；占位符则表示需要动态填入的具体数据项，

通常以大括号“{}”的形式呈现。

为高效构建一个多样化的任务指令集，本系统采取了人工编写与通用大语言模型协作相结合的策略。在初期阶段，系统基于对不同医疗质控任务的深入理解，手动编写了一系列初始任务指令。例如，在针对肺癌切缘阴性率计算任务时，一个典型的人工编写的指令可能是：

“{</start>}instruction: 请根据提供的电子病历内容判断肿瘤支气管切缘是否为阴性。如果描述为‘切缘无肿瘤组织累及’或相似表述，则判断为阴性；若为‘切缘可见肿瘤细胞浸润’或相似表述，则判断为阳性。如为阴性，请进一步判断是否存在转移淋巴结。input: 支气管切缘无肿瘤组织累及 {</end>}”在该示例中，任务描述为 ...

instruction 以及 input，而占位符为 </start>、</end>对。

总而言之，本系统通过结合开源数据集与人工设计模板，能够从真实世界医疗

数据中提取关键信息，构建与实际医疗实践密切相关的多样化质控指标任务指令数据集，从而进一步提升模型在医疗质量控制领域中的应用效果。

4.1.2 微调过程

模型指令微调部分采用“任务渐进式微调”的训练策略，旨在逐步增强模型在医疗领域的专业处理能力，并确保其能够有效适应多样化的医疗质控任务。该方法通过综合分析任务难度和数据特性，对训练顺序和训练轮次进行优化，使模型能够从简单任务逐步积累经验，并逐步扩展到更复杂的任务类型。在初期阶段，先将电子病历规范检查任务作为模型的初始训练任务，进行少轮次的训练。这一阶段的训练目的是让模型掌握医疗文档的基本处理要求和格式检查能力，为后续的复杂任务打下扎实的基础。

随着模型逐步适应初期任务，引入医疗质控指标计算任务，进行较多轮次的训练。这一阶段的训练使模型在原有基础上逐步提高其文本处理和数据分析能力，并能够灵活适应医疗质量控制的复杂任务。

这样的“渐进式”训练模式，依次引入不同的任务，确保模型在每个阶段都有针对性的能力提升。相比于传统的单一任务或联合任务训练，通过阶段性调整训练任务的难度和频次，能够确保模型在能力逐步积累的同时，不会因任务过于复杂而产生不稳定现象。此外，这种有序的任务安排有助于模型建立不同任务间的联系，从而提升其多任务学习的整体表现。

在各项单独任务训练完成后，将所有任务数据整合到一个联合训练阶段，通过多任务微调强化模型的泛化能力。该联合训练阶段的设计旨在通过综合性的数据输入，使模型能够将各个任务的学习成果进行整合，并提升其在多样化医疗任务中的表现。这样一来，模型不仅能在单项任务中保持较高的准确度，还能够在面对多任务组合时展现出更为一致的稳定性和适应性。

4.2 医疗质控指标计算

4.2.1 自动化指标计算

表 1 质控指标的要求及说明

指标名称	指标定义	指标说明
非瓣膜性心房颤动（房颤）患者血栓栓塞风险评估率	单位时间内，行血栓栓塞风险评估的非瓣膜性房颤患者数，占同期非瓣膜性房颤患者总数的比例	血栓栓塞风险评估推荐采用 CHA2DS2-VASc 评分。
冠脉介入治疗术后即刻冠状动脉造影成功率	单位时间内，冠脉介入治疗术后即刻冠状动脉造影成功的例数，占同期接受冠脉介入治疗的总例数的比例	冠状动脉造影成功是指支架术后病变残余狭窄<20%或单纯经皮冠状动脉腔内血管成形术（PTCA）后病变残余狭窄<50%，且冠状动脉血流心肌梗死溶栓（TIMI）分级 3 级。

表 2 质控指标的任务拆分

指标名称	指标说明	任务拆分
冠脉介入治疗术后即刻冠状动脉造影成功率	冠状动脉造影成功是指支架术后病变残余狭窄<20%或单纯经皮冠状动脉腔内血管成形术（PTCA）后病变残余狭窄<50%，且冠状动脉血流心肌梗死溶栓（TIMI）分级 3 级。	Task1：做过支架术 if 狭窄<20% Task2：做过 PTCA if 狭窄<50% Task3：TIMI 分级为 3 级

由于各类质控指标在计算复杂性上存在显著差异，仅凭 LLM 从电子病历中直接抽取文本、判断是否符合要求的方式并非总能满足需求。例如，表 1 中列出的“非瓣膜性心房颤动（房颤）患者血栓栓塞风险评估率”和“冠脉介入治疗术后即刻冠状动脉造影成功率”便展示了这一点的差异。前者的计算相对简单，只需判断电子病历中是否记录了 CHA2DS2-VASc 评分或栓塞风险评分即可；而後者的评估则相对复杂，需要综合残余狭窄程度、TIMI 情况以及手术类型等因素进行准确计算。因此，无法简单地将指标定义、计算公式和相关电子病历内容直接传送给 LLM 处理。为了提高计算的准确性和效率，在输入这些复杂的指标定义和计算公式之前，有必要将其拆分为多个简单的子任务，以便 LLM 更精确地理解 and 处理每个指标的具体要求。

为了提升 LLM 对质控指标的理解能力，复杂指标需要被拆分为若干独立的子任务。通过简单的逻辑规则整合各子任务的符合情况，即可还原出原始质控指标的符合情况。例如，以“冠脉介入治疗术后即刻冠

状动脉造影成功率”指标为例，根据其定义，“冠状动脉造影成功”需满足以下条件：支架术后病变残余狭窄<20%；或单纯经皮冠状动脉腔内血管成形术（PTCA）后病变残余狭窄 <50%；并且冠状动脉血流心肌梗死溶栓（TIMI）分级达到 3 级。基于此定义，可将该指标拆分为三个子任务：

- Task1：残余狭窄<20%时，判断患者是否接受过支架术；
- Task2：残余狭窄<50%时，判断患者是否接受过 PTCA；
- Task3：判断患者的 TIMI 分级是否为 3 级。

最终，通过计算逻辑表达式(Task1

Task2) Task3 的结果，可以得出该患者冠

脉介入治疗术后即刻冠状动脉造影是否成功的结论。表 2 给出了具体的拆分结果。

尽管各个子任务准确描述了所需关注的细节，但其表述可能过于简洁，存在潜在歧义或遗漏具体的应用场景，从而可能

导致 LLM 误解子任务目标，产生偏离预期的回复。为了解决这一问题，本文采用 RAG 技术，从先前收集的质控指标说明和权威医学文献中提取与子任务最相关的段落，作为额外的知识补充。

按原本定义，LLM 接收的输入包括<指标定义, 指标计算公式, 电子病历>，其对自然语言中蕴含的谓词逻辑可能存在理解偏差。通过任务拆分过程，以<指标定义, 指标计算公式>为输入，生成输出<{子任务}m, 电子病历>，并借助检索增强生成（Retrieval-Augmented Generation，RAG）技术，为每个子任务匹配最相关的医学知识作为补充，进一步输出<{子任务}m, 知识, 电子病历>。这使得原本可能导致歧义的输入被转化为 LLM 更易理解的<{子任务}m, 知识, 电子病历>格式。这种改进不仅缓解了 LLM 对复杂谓词逻辑的理解偏差，还激发了其在处理弱逻辑化子任务时的潜力，同时显著提升了解释性。通过这一过程，任务拆分与 RAG 的结合有效增强了 LLM 的分析能力，为实现更准确的判断奠定了基础。图 2 给出了本系统的计算结果页面。

4.2.2 自动化指标计算的结果对比

表 3 指标计算的结果对比

模型	方法	准确度(%)
ChatGLM3-6B	ICL	71.47
PULSE-20B	ICL	84.38
医疗质控应用系统	Zero-shot	85.58
医疗质控应用系统	ICL	88.53
医疗质控应用系统	Ours	93.31

为了验证自动化指标计算方法的有效性，本文选取国内的 ChatGLM3-6B 与本框架使用的基座模型 PULSE-20B 进行模型对比，并采用 Zero-shot^[25]（仅提供指令）和 ICL^[26]（In-Context Learning，提供完整指令、输入、输出的示例）两种推理方法进行对比。

相比 ChatGLM3-6B，医疗质控应用系统的参数量更大，具备更强的学习与计算能力。因此，即便采用 Zero-shot 方法，医疗质控应用系统的准确度已领先 ChatGLM3-6B 约 14.11%；而结合本框架的自动化指标计算方法，其准确度更是达到 93.31%。与基座模型 PULSE-20B 相比，医疗质控应用系统因获得了更多医学知识的微调，对医学领域的理解更为深入和透彻。在使用相同的 ICL 推理方法下，医疗质控应用系统的准确度相较 PULSE-20B 提升了 4.15%。如果采用本文提出的更优化的推理方式，其准确度可再提升 4.78%。具体的对比结果如表 3 所示。

综上所述，医疗质控应用系统在推理方法与模型性能方面均展现出卓越的潜力和优势，充分证明了其可靠性。



图 2 医疗质控应用系统的指标计算页面

5. 结语

本研究提出了一种基于大语言模型的医疗质量控制应用系统，旨在提升医疗质控的自动化水平与准确性。本系统采用了标准化的数据处理与指令微调方法，解决了医疗大模型中的数据低质量和专业性不足问题。通过基于临床指南和专家共识构建高质量医学数据集，结合增强训练策略，确保了模型能够高效应对复杂的医学任务。本系统还提出了自动化指标计算方法，利用任务拆分与检索增强生成技术，解决了医疗指标计算中的复杂逻辑问题，从而提高了计算效率与准确性。

该系统为医疗质控的自动化与智能化发展以及大语言模型在医疗领域的深度应用提供了可行的技术路线。随着技术的不断进步，类似的智能化质控系统预计将在更多医疗机构中得到广泛应用，推动医疗质量管理的现代化进程。

作者贡献：吴宏、胡军负责论文撰写；陈尔真、董晨杰负责采集、整理数据、文献调研；李建华、叶琪负责论文构思、指导、审阅。”

利益声明：所有作者均声明不存在利益冲突。

参考文献

[1] 王飞,张春燕,张付静,等. "大质控"理念下医疗质量管理体系的构建与实践探索[J]. 中国卫生标准管理,2023,14(13):50-54.

[2] Lee R I,Jones L W.The fundamentals of good medical care[J].Publications of the Commi ttee on the Costs of Medical Care,1933,22.

[3] 黄素华.论医疗机构单病种质量控制的研究[J]. 广西医学,2004,26(3):443—444.

[4] 刘少堃,何仲廉,李彬,等. 基于大模型的电子病历自动生成系统的设计与应用探讨[J]. 中国数字医学,2024,19(8):8-13.

[5] 陈依萍,周露,李亦学. 基于大模型的电子病历与CDA 标准模式映射方法研究[J]. 中国卫生信息管理杂志,2023,20(6):867-874.

[6] 浙江大学医学院附属第二医院: 在电子病历系统中嵌入人工智能大模型[J]. 中华医学信息导报,2024,39(15):9.

[7] 郝宁. 信息化管理在医疗质量控制中的应用[J]. 邯郸职业技术学院学报,2023,36(4):34-37.

[8] 阮彤,卞保昂,余广涯,等. 医学大语言模型研究与应用综述 [J]. 中国卫生信息管理杂

志,2023,20(6):853-861.

[9] 刘泓泽,王耀国,唐圣晟,等. 医学大语言模型的应用现状与发展趋势研究 [J]. 中国数字医学,2024,19(8):1-7,13.

[10] Brown T B, Mann B, Ryder N, Subbiah M, et al. Language Models are Few-Shot Learners[J]. arXiv preprint arXiv:2005.14165,2020.

[11] Gemini Team, Anil R, Borgeaud S, et al. Gemini: A Family of Highly Capable Multimodal Models[J]. arXiv preprint arXiv:2312.11805,2023.

[12] TOUVRON H,LAVRIL T,IZACARD G,et al. Llama: Open and efficient foundation language models[J]. arXiv preprint arXiv:2302.13971, 2023.

[13] Bai J, Bai S, Chu Y, et al. Qwen Technical Report[J]. arXiv preprint arXiv:2309.16609, 2023.

[14] Zhang H, Chen J, Jiang F, et al. HuatuoGPT, Towards Taming Language Model to Be a Doctor[C]. BOUAMOR H, PINO J, BALI K. //Findings of the Association for Computational Linguistics: EMNLP 2023. Singapore:Association for Computational Linguistics,2023: 10859–10885.

[15] Chen Y, Wang Z, Xing X, et al. BianQue: Balancing the Questioning and Suggestion Ability of Health LLMs with Multi-turn Health Conversations Polished by ChatGPT[J]. arXiv preprint arXiv:2310.15896.

[16] Liao Y, Jiang S, Wang Y, Wang Y. MING-MOE: Enhancing Medical Multi-Task Learning in Large Language Models with Sparse Mixture of Low-Rank Adapter Experts[J]. arXiv preprint arXiv:2404.09027.

[17] Yang S, Zhao H, Zhu S, et al. Zhongjing: Enhancing the Chinese Medical Capabilities of Large Language Model through Expert Feedback and Real-world Multi-turn Dialogue[J]. arXiv preprint arXiv:2308.03549.

[18] 宋雪君. 电子病历在医疗质量控制管理中的应用与研究[J]. 现代计算机,2023,29(6):88-90.

[19] 冯园园,苏源,来庆玲,等. 基于 3 级质控管理的电子病历系统流程优化研究[J]. 医学信息学杂志,2023,44(4):73-77.

[20] 周芮,陈彦东,宿明. 基于大数据和 AI 的电子病历自动质控系统构建 [J]. 医学信息,2022,35(4):13-16.

[21] 刘晓娇,黄春芳,朱玉婷,等. 基于临床数据中心的单病种质控管理平台的实践[J]. 中国医疗设备,2023,38(2):90-94,130.

- [22] 蔡子杰,方荟,刘建华,等. 基于大型语言模型指令微调的心理健康领域联合信息抽取[J]. 中文信息学报,2024,38(8):112-127.
- [23] Ding, N., Qin, Y., Yang, G. et al. Parameter-efficient fine-tuning of large-scale pre-trained language models. *Nature Machine Intelligence*, 2023, 5:220–235.
- [24] Shayne Longpre, Le Hou, Tu Vu. et al. The flan collection: designing data and methods for effective instruction tuning[C]//*Proceedings of the 40th International Conference on Machine Learning (ICML'23)*, Honolulu, Hawaii, USA, JMLR.org, 2023: 22631–22648.
- [25] Jason Wei, Maarten Bosma, Vincent Zhao. et al. Finetuned Language Models are Zero-Shot Learners[C]//*The Tenth International Conference on Learning Representations*, 2022.
- [26] Wies, N.; Levine, Y.; and Shashua, A. The learnability of in-context learning[C]//*Advances in Neural Information Processing Systems*, 2024.