

DOI:10.13232/j.cnki.jnju.2019.06.007

基于深度学习和多特征融合的中文电子病历 实体识别研究

韩 普^{1,2*}, 刘亦卓³, 李晓艳⁴

(1. 南京邮电大学管理学院, 南京, 210023; 2. 江苏省数据工程与知识服务重点实验室, 南京大学, 南京, 210023;
3. 南京大学信息管理学院, 南京, 210023; 4. 南京医科大学基础医学院, 南京, 211166)

摘 要: 电子病历实体识别是医疗领域人工智能和医疗信息服务中非常关键的基础任务。为了更充分地挖掘电子病历中的实体语义知识以提升中文医疗实体识别效果, 提出融入外部语义特征的中文电子病历实体识别模型。该模型首先利用语言模型 word2vec 将大规模的未标记文本生成具有语义特征的字符级向量, 接着通过医疗语义资源的整合以及实体边界特征分析构建了医疗实体及特征库, 将其与字符级向量相拼接以更好地挖掘序列信息, 最后采用改进的 Voting 算法将深度学习结果与条件随机场(Conditional Random Fields, CRF)的结果加以整合来纠正标签偏置。实验表明, 融入外部语义特征的改进模型的 F 值达到 94.06%, 较 CRF 高出 1.55%。此外, 还给出了模型最佳效果的各项参数。

关键词: 医疗实体识别, 深度学习, 电子病历, 人工神经网络

中图分类号: TP391.1

文献标识码: A

Named entity recognition from Chinese medical records based on deep learning and multi-feature fusion

Han Pu^{1,2*}, Liu Yizhuo³, Li Xiaoyan

(1. School of Management, Nanjing University of Posts & Telecommunications, Nanjing, 210023, China;
2. Jiangsu Provincial Key Laboratory of Data Engineering and Knowledge Service, Nanjing University, Nanjing,
210023, China; 3. School of Information Management, Nanjing University, Nanjing, 210023, China;
4. School of Basic Medical Sciences, Nanjing Medical University, Nanjing, 211166, China)

Abstract: Named entity recognition of electronic medical record is a key basic task in the field of medical artificial intelligence and medical information service. In order to fully explore the semantic knowledge of medical entity in electronic medical records to improve the effect of Chinese medical entity recognition, BiLSTM(Bi-Long Short Term Memory)-withfea model incorporating external semantic features is proposed. The model first generates a character-level vector with semantic features using the large-scale unlabeled medical texts based on word2vec. Second, a medical entity and feature database for entity recognition is constructed according to the integration of the existing medical resources and the analysis of different types of entity boundary characteristics. Then, the database is converted into

基金项目: 国家社会科学基金(17CTQ022)

收稿日期: 2019-08-13

* 通讯联系人, E-mail: hanpu@njupt.edu.cn

vectors to join with character-level vectors to fully exploit the sequence information. Finally, the experimental result is integrated with the output of the CRF (Conditional Random Fields) by the improved Voting algorithm to correct the label offset. Experiments show that the F -measure of the improved model reaches 94.06%, which is 1.55% higher than CRF. In addition, the parameters of the optimal effect of the improved model are given.

Key words: medical entity recognition, deep learning, electrical medical records, artificial neural network

电子病历是临床医生对患者就医过程中各种病程的记录,蕴含着宝贵的医学健康知识。随着人工智能在医疗领域的推进,针对电子病历的文本挖掘和自然语言处理受到社会各界的极大关注^[1-2]。在电子病历的信息抽取和知识挖掘中,医疗实体识别是一项非常重要的基础性研究。和传统命名实体不同的是,医疗实体是指具有重要意义的医学概念,如疾病、症状、检查和器官等^[3]。与通用领域相比,医疗实体构词十分复杂,存在大量的实体嵌套现象,识别难度更高。针对这一任务,国内外学术界近年发起了多个针对医疗实体识别的竞赛,影响力较大的有 i2b2 公开发起的一系列医疗实体识别测评会议,如 2009 年的药物识别竞赛;2010 年的针对疾病、治疗和检查实体的识别竞赛,还发布了公开的英文电子病历标注语料,该次竞赛的影响力非常大,为后续研究提出了参照标准。

针对中文医疗实体识别的问题,国内学界在 2017 年和 2018 年举办了中文电子病历的实体识别评测。医疗实体的识别可分为基于词典的识别方法、基于规则的识别方法和基于机器学习的识别方法。虽然基于词典的方法在药物识别竞赛中取得了较好的结果^[3],但该方法最大的问题在于不能识别未登陆词,并且词典本身的构建和维护均需要较大代价,因此在实体识别中通常作为补充或对照方法。Segura-Bedmar et al^[4]在加入词典后药物实体识别的召回率和准确率均有提升,整体 F 值提高了 1%。针对医疗实体词的构成,不少学者尝试通过分析实体的词性、上下文和边界特征来制定规则。叶枫等^[5]在使用条件随机场模型时,选取语言符号特征、词性、词边界和上下文作为特征集对疾病、症状和手术操作等医疗实体进行识别研

究。Hu et al^[6]针对不同类型的医疗实体构建了相应规则,并取得了较好的实验效果。虽然规则在一定程度上可以提升实体识别的效果,但由于各类文本的表述并没有统一规范,基于先验知识的规则则非常复杂,并且可迁移性较差,因此该方法通常和其他方法一起使用。

机器学习是目前医疗实体识别中最流行的方法,常见的有最大熵、支持向量机(Support Vector Machine, SVM)、隐马尔可夫、条件随机场(Conditional Random Fields, CRF)及深度学习模型。在通常的命名实体识别任务中,CRF 和 SVM 有非常相近的效果^[7]。Jiang et al^[8]发现 CRF 对英文医疗实体的识别效果优于 SVM。Lei et al^[9]对 CRF, SVM, SSVM (Structural SVM) 和 ME (Maximum Entropy) 四种方法进行了对比,发现 SSVM 方法在中文医疗实体识别中略好于其他方法。针对电子病历语料标注的难题,在不增加标注量的前提下,王润奇和关毅^[10]基于 Tri-Training 的半监督学习方法进行中文医疗实体识别。近年来深度学习在语音识别、图像识别和视频分析等多个领域取得了重大进展^[11],在文本挖掘领域,深度学习通过学习和训练能较好地表征大规模文本数据的语义特征。和传统机器学习方法相比,深度学习在面对海量的数据任务时更占优势。

在采用深度学习的命名实体识别研究中,Lample et al^[12]提出用双向长短期记忆模型(Bi-Long-Short Term Memory, BiLSTM)和 CRF 模型相组合的结构进行标签预测,该组合模型在四种语言的实体识别任务中均取得了最好结果。基于 2010, 2012 和 2014 年 i2b2 测评的英文电子病历,Liu et al^[13]设计了多组对照实验,发现 LSTM 模型优于 CRF 模型。从已有文献来

看,深度学习在实体识别中有较好的表现.随着词嵌入技术的发展,实体语义特征得以更充分地表示,因而深度学习算法在文本挖掘研究中得到了进一步发展. Ma and Hovy^[14]在 BiLSTM-CRF 模型中加入字符级 Embedding,在 CoNLL2003 语料集上的实体识别取得了 91.21% 的 F 值. 基于 BiLSTM-CRF 模型, Chalapathy et al^[15]将词表示工具生成的词向量引入实体识别,取得了较好的结果. Wu et al^[3]利用大规模无标注语料生成词向量输入深度学习模型,得到的 F 值比 CRF 高 0.8%. Hu et al^[6]在 LSTM 模型中加入实体的各种特征以提升医疗实体识别效果. Wu et al^[16]在 LSTM-CRF 模型中通过改进分词方法、加入一致性检验等策略来提升医疗实体识别效果.

可以发现,电子病历中的医疗实体识别在国内外已经取得了大量的研究成果,但基于深度学习的中文医疗实体识别研究尚未引起足够的重视. 虽然深度学习在通用领域的实体识别任务中取得了较好的效果,但在医疗领域中,医疗实体构成复杂、实体嵌套现象严重、实体修饰不明确、同一实体有多种别名和缩写等问题增加了医疗实体识别的难度;医疗领域人工智能和医疗信息服务等应用对实体识别的要求也较高,因此医疗实体识别既是医疗信息处理和分析的重点,也是难点. 鉴于此,本文在中文电子病历医疗实体识别任务中提出了改进的 BiLSTM-CRF 模型,在模型中尝试融入更多外部医疗实体语义知识以提升医疗实体识别效果,并通过改进的 Voting 算法将深度学习结果与 CRF 结果进行整合以避免标签偏置的问题.

1 深度学习模型

1.1 循环神经网络 循环神经网络(Recurrent Neural Network, RNN)^[17]是一种扩展的人工神经网络,也是深度学习算法中的基本模型之一,常用于自然语言处理、语音识别等序列数据预测等研究. RNN 中各层共享同样的参数,并且具有记忆特性,理论上能够存储当前元素

前向(后向)任意长度的序列. 和 CRF 相比, RNN 对长期依赖(Long-Term Dependencies, LTD)问题的处理效果更好. RNN 的结构可抽象为图 1 所示的形式,神经元结构如图 2,其内部包含一个 tanh 层.




图 1 循环神经网络

Fig. 1 Recurrent neural network




图 2 RNN 神经元

Fig. 2 RNN neuron

RNN 的计算方法可表示为:

$$S_t = f(U \times X_t + W \times S_{t-1}) \quad (1)$$

$$o_t = \text{softmax}(V \times S_t) \quad (2)$$

其中, X_t 表示 t 时刻的输入, o_t 表示 t 时刻的输出, S_t 表示 t 时刻隐藏层值, f 表示网络的激活函数, U, V 分别表示输入、输出权重, W 为相邻隐藏层间的权值矩阵.

虽然 RNN 理论上能够保存 t 时刻之前(后)任意长度的记忆,但若序列中某一时刻同时需要前向和后向信息时, RNN 就满足不了,因此引入双向循环神经网络(Bi-directional Recurrent Neural Network, BiRNN)解决该问题, BiRNN 的结构如图 3.

由 BiRNN 模型可以看出,其隐藏层每个时刻都需要保存两个值,一个为 s , 参与前向计算,




图3 双向循环神经网络

Fig. 3 Bidirectional Recurrent Neural Network

传递过程由实线表示；另一个为 s' ，参与后向计算，传递过程由虚线表示。相应隐藏层每个时刻接收的值也有前向和后向两个信息。

1.2 长短时记忆网络 实际应用中循环神经网络处理长距离依赖的能力较弱，即难以学习到较远距离的信息，因而会产生梯度消失 (Vanishing Gradient)^[18]，因此出现了改进的循环神经网络，如 LSTM^[19]，该模型用于克服传统 RNN 模型序列过长产生梯度弥散的问题。LSTM 为了实现时间上的记忆功能，在 cell 中引入输入门、输出门和遗忘门三个控制门。

LSTM 与传统的 RNN 结构相同，但其核心思想是细胞 (Cell) 状态，具体结构如图 4，其中 C 为 cell 存储的记忆信息，贯穿整个模型。在 t 时刻，cell 的输入有 $t-1$ 时刻的记忆信息 C_{t-1} 、输出信息 s_{t-1} 以及当前时刻的输入值 x_t 。cell 得到输入后，将 s_{t-1} 与 x_t 拼接为组合信息，首先通过遗忘门^[20]决定从 C_{t-1} 中丢弃的信息，用输入门决定要更新的位置，并用 tanh 层计算更新的结果；接着将结果更新到 C_t 中；最后通过输出门确定细胞状态的输出部分，将 C_t 通过 tanh 层处理并将其与输出门的输出相乘，最终输出结果 s_t 和 C_t 。各个门的更新方式如图 4。

遗忘门：

$$f_t = \text{sigmoid}(W_f \times [s_{t-1}, x_t] + b_f) \quad (3)$$

输入门：

$$i_t = \text{sigmoid}(W_i \times [s_{t-1}, x_t] + b_i) \quad (4)$$

计算更新的信息：

$$C'_t = \tanh(W_c \times [s_{t-1}, x_t] + b_c) \quad (5)$$

更新细胞状态：




图4 LSTM 神经元

Fig. 4 LSTM neurons

$$C_t = f_t \times C_{t-1} + i_t \times C'_t \quad (6)$$

输出门：

$$o_t = \text{sigmoid}(W_o \times [s_{t-1}, x_t] + b_o) \quad (7)$$

计算输出：

$$s_t = h_t = o_t \times \tanh(C_t) \quad (8)$$

其中， W 和 b 分别表示遗忘门、输入门和输出门的权重矩阵和偏置向量。BiLSTM 网络与 BiRNN 的结构相同，相应的， C 中同时存储前向和后向信息。

1.3 BiLSTM-CRF 鉴于 BiLSTM-CRF 模型在序列标注任务上的优势^[12,21]，本文采用该模型进行中文电子病历的实体识别。BiLSTM 通常后接一个 softmax 层输出各标签的概率，但各个概率相互独立，只在每一步挑选最大概率值的标签输出，因此会出现前后标签连接错误，即标签偏置^[22]。本文采用图 5 的改进模型来解决这个问题。在改进模型中，BiLSTM 层后接 CRF 层是为了描述标签间的依赖关系，模型可以同时利用 LSTM 层学习的长距离输入特征和 CRF 层学习的转移特征，此时 CRF 输入为 LSTM 输出的状态转移矩阵，因此可以使用动态规划计算最佳标签序列。

模型最底层为字符拆分后的输入序列 $X = \{x_1, x_2, x_3, \dots, x_n\}$ ，通过 Look-up 层，用预训练的字符向量矩阵将每个字映射为字符级 embedding，作为双向 LSTM 的输入层。LSTM 层输出一个 $n \times k$ 维矩阵 $\{p_1, p_2, p_3, \dots, p_n\} \times k$ ，其中 n 为序列长度， k 为需要预测的标签个数， p_{ij} 为 x_i 对应第 i 个标签的概率。将序列 P 输入 CRF 层，




图 5 改进的 BiLSTM-CRF 模型

Fig. 5 The improved BiLSTM-CRF model

由 CRF 解码得到最优标注序列 $Y = \{y_1, y_2, y_3, \dots, y_n\}$, 计算如下:

概率计算:

$$K(X, y) = \sum_{i=0}^n A_{y_i, y_{i+1}} + \sum_{i=1}^n P_{i, y_i} \quad (9)$$

预测:

$$y^* = \operatorname{argmax} K(X, y') \quad (10)$$

其中, y' 为此时 x 的标签, A 为转移矩阵. 由于序列中加入了开始和结束标志, 矩阵 A 的形式为 $(k+2)$ 阶方阵.

2 实验设计

2.1 实验流程设计 为验证改进模型的效果, 设计如图 6 所示的整体流程. 首先, 对获取的电子病历进行预处理, 抽取其中的正文文本, 为保护患者隐私, 还需要进行脱敏处理; 接着进行医疗实体标注; 然后采用 CRF, BiLSTM-CRF 和 LSTM-withfea (引入实体及特征库作为特征向量输入的改进 BiLSTM-CRF 模型) 三种模型进行对照实验, 将三种模型的预测结果用 Voting

算法进行投票. 在两种深度学习模型中, 均采用 word2vec 将未标注电子病历以及医疗问答社区数据生成的词向量用于训练神经网络.




图 6 整体实验流程

Fig. 6 The flow chart of the experiment

2.2 词向量生成 word2vec 模型^[23]将每个词映射到一个向量, 用来表示词与词间的关系, 主要有 Skip-Gram 和 CBOW 两种模型. Skip-Gram 模型通过输入一个词预测其上下文, 而 CBOW 通过上下文来预测该词本身. 本文利用医疗论坛的 36745 个问答帖以及 500 篇未标注的电子病历生成字符级向量. 具体的, 经过预处理后, 首先利用 Gensim 包中的 word2vec 函数将语料生成字向量, 接着将输入序列转换为字符级 Embedding. 通过对 Skip-Gram 和 CBOW 两种模型的分析, 本文采用 Skip-Gram 生成词向量, 该模型思路如图 7.




图 7 Skip-Gram 模型

Fig. 7 Skip-Gram model

如电子病历中有一序列“双腕关节肿胀疼痛”, 以“节”作为输入字符, 设置窗口长度为 5, 则窗口中的序列为 [腕, 关, 节, 肿, 胀], 可用 $[w_{(i-2)}, w_{(i-1)}, w_i, w_{(i+1)}, w_{(i+2)}]$ 表示. 图 7 中输入向量 x 为 one-hot 编码 $[0, 0,$

$1, 0, 0]$. 要学习的目标为输入层和隐藏层间的权重矩阵 W 和隐藏层与输出层间的权重矩阵 W' , 若词表中共有 n 个词, 则第 c 个词出现的概率分布为:

$$P(w_c|w_i) = \frac{\exp(V_c \times W'_c)}{\sum_{k=1}^n V_c \times W'_k} \quad (11)$$

其中, 隐藏层得到的向量 V_c 为 x 与 W 的乘积, W'_k 为权重矩阵 W' 的第 k 列.

2.3 医疗实体及特征库构建 中文电子病历包含大量的固定实体和具有明显类别特征的实体, 如组织器官、治疗和疾病实体, 有明显的类别特征. 国内有学者利用语言符号、词性等五种特征来提升电子病历实体识别的效果^[5]. 本文通过人工收集并构建医疗实体及特征库为每个输入元素生成对应特征, 进而为模型提供更丰富的实体特征信息. 此外, 在医疗实体标注过程中发现疾病、药物以及手术类实体有着较为固定的边界, 如“xx 病(炎、囊肿、溃疡)”和“xx 术”等特征. 通过对电子病历中医疗实体频次、边界特征和结构的分析, 在国际疾病分类词典 ICD11、搜狗医学词库以及在线百科医疗百科资源基础上, 最终构建了适用于本研究的医疗实体及特征库, 其基本信息如表 1.

表 1 中文医疗实体及特征库

Table 1 Chinese medical entity and feature base

类别	数量	例子
组织器官	349	直肠、甲状腺、双侧股动脉
医药及 手术后缀	32062	脉管康复片、锋泰灵 全切术、固定术、切除
疾病后缀	175	病、癌

2.4 融入外部语义特征的电子病历实体识别 在利用外部语义特征时, Hu et al^[6] 首先在输入层将文本转换为向量, 接着输入 LSTM 神经网络, 再将其构建的特征与 BiLSTM 层的输出拼接后传递给 tanh 隐藏层, 最后由隐藏层输出标注结果. 与此不同, 本文采用图 8 的方法融入语义特征向量, 即在输入层便将特征向量与输入序列拼接, 然后将新的向量直接传递给

BiLSTM 网络, 可以更早地挖掘更丰富的语义特征. 简单地说, 本文的思路是首先将特征通过 Look-up Table 转化为特征向量, 接着将此向量与输入序列的词表示在模型的 BiLSTM 层之前拼接得到新的输入向量.




图 8 特征拼接流程

Fig. 8 The flow chart of feature stitching

2.5 改进 Voting 算法 多数投票 (Majority Voting) 是用于寻找多数元素的算法, 通常用来整合多个实验以得到理想结果. 本研究首先利用三种模型开展实验, 然后通过 Voting 算法整合多个结果. 传统 Voting 算法的思路是: 若某实体对应的标签均由两个或两个以上的模型识别出来, 则结果确定为该标签, 否则定为 O 类标签. 若存在两个错误的结果, 则最终结果也为错误或为 O 类标签, 因此传统的 Voting 算法结果不会优于参与投票的最优模型.

在 BiLSTM-CRF 模型的预测结果中, 标签偏置的问题虽已大大减少, 但仍然存在如预测的实体边界错误、实体无效化等问题, 而 CRF 的预测结果则不会出现这些问题. 所以, 本文首先对三种模型的结果采用传统 Voting 算法得到第一个结果, 记为 fst_result , 然后对该结果进行检查, 如存在标签偏置, 则将该标签替换为 CRF 结果. 若该处在 CRF 结果中位于一个实体内部, 则前向或后向将整个实体置换为 CRF 标注结果, 得到 sec_result 并输出.

2.6 对照实验设计 为验证模型的实验效果并寻找模型最优参数, 设计两组实验:

实验一: 检验并对比 CRF, BiLSTM-CRF 和 LSTM-withfea (LSTM-withfea 表示引入实体以及特征库作为特征向量输入的改进 BiLSTM-CRF 模型) 三种模型的医疗实体识别效

果,并将三个结果作为 Voting 算法的输入进行实验.

实验二:寻找最优的神经网络模型参数:在 LSTM-withfea 模型中,通过不同的词向量训练参数进行实验;使用 word2vec 生成 300 维向量,改变神经网络训练时的各项参数进行实验.

3 实验及结果分析

3.1 实验环境及数据 所有实验均在一台浪潮四核服务器上运行,Intel(R) Xeon(R) CPU E5-2407 2.20 GHz,内存 16 GB. 操作系统 Deepin GNU/Linux 15.5, CRF 运行版本 CRF++-0.58,神经网络框架 tensorflow1.4-cpu,运行环境为 python 3.6.4.

由于目前没有公开的大规模中文电子病历标注数据集,因此本研究组通过学习、培训和统一标注规范等大量准备工作标注了一定规模的中文电子病历语料. 在已有研究基础上将医疗实体分为疾病(Disease)、症状(Symptom)、组织器官(Organ)、检查(Check)和治疗(Treatment)五类. 标注各类实体时以首字母代替,并用 BIESO 方式标注. 其中 B, I, E 分别表示实体开始、中间和结束, O 表示非实体, S 表示为单独实体. 为减小中文分词对医疗实体识别的影响,标注医疗实体时用基于字的标注方式,这也是目前实体识别研究中常用的做法^[5,9]. 研究小组标注了 310 篇中文电子病历,共 28 万多字,各类实体数量如表 2. 这些病历来自江苏某医院风湿科,实验时将所有病历随机打乱,按 9:1 划分为训练集和测试集,进行十折交叉验证,取十次结果的平均值作为最终结果. 此外,还有从好问康、求医问药网获取的论坛问答数据用于训练词向量,包含帖子 36745 个,共 105 MB.

实体识别效果评价标准通常采用机器学习领域常用的指标:准确率 P (Precision), 召回率

表 2 实体数量统计

Table 2 Statistics of entities

实体类型	症状	疾病	器官	治疗	检查	全部实体
实体数量	11676	2418	5162	1429	3620	24305

R (Recall) 以及调和平均值 F 值 (F -measure), 计算公式如下:

$$P = \frac{TT}{TT + TF} \quad (12)$$

$$R = \frac{TT}{TT + FT} \quad (13)$$

$$F = 2 \times \frac{P \times R}{P + R} \quad (14)$$

其中, TT 表示将正类标签预测为正(预测正确), FT 表示将负类标签预测为正(预测错误), TF 表示将正类标签预测为负(预测错误).

3.2 实验结果及分析

3.2.1 实验一 各模型的十折交叉验证的实验结果如表 3 和表 4, 各数据为十次实验结果的平均值, 黑体字为最优结果.

表 3 各模型的实验结果(%)

Table 3 Experimental results of each model (%)

模型	Precision	Recall	F -measure
CRF	94.09	90.98	92.51
BiLSTM-CRF	94.50	92.35	93.41
BiLSTM-withfea	96.04	92.16	94.06
Voting	95.53	92.38	93.93

表 4 各类实体识别的 F 值(%)

Table 4 F value of different types of entities recognition (%)

模型	症状	疾病	器官	治疗	检查	整体
CRF	92.95	96.82	95.94	89.18	87.45	92.51
BiLSTM-CRF	94.10	96.38	95.80	90.21	90.23	93.41
BiLSTM-withfea	94.37	96.80	97.18	90.30	89.21	94.06
Voting	94.21	96.58	95.94	93.44	90.85	93.93

由表 3 可以看出, 加入外部语义特征的 BiLSTM-withfea 模型的整体 F 值最优, 而使用 Voting 算法将三种模型输出整合的结果次之, 高于 CRF 模型与不带特征的深度学习模型.

由表 3 和表 4 可以发现, BiLSTM-withfea 的整体预测结果好于 CRF 和 BiLSTM-CRF,

引入组织器官特征后,组织类实体识别率较不含特征的 BiLSTM-CRF 模型提高了 1.38%。但也有例外,检查类实体的识别效果低于 BiLSTM-CRF 模型,主要原因是一方面所构建的医疗实体及特征库中没有包含检查类实体的特征,另一方面也可能是受到了其他特征的干扰。整体上,除检查类实体外,其他三类实体识别的 F 值均有提升,表明本文构建的实体及特征库能够提升中文医疗实体识别效果。

表 5 给出了各模型预测结果中存在标签偏置错误的实体数和预测出的总实体数(包含偏置实体),其中 BiLSTM-CRF 与 BiLSTM-withfea 模型结果由十次结果平均后取整数而得到。由表 5 可知,虽然 Voting 方法得到结果的 F 值较 BiLSTM-withfea 模型结果低 0.13%,但 Voting 算法结果中不存在标签偏置错误,这表明投票算法在标签纠正方面有较好的表现。

表 5 各模型中偏置实体数量及比例

Table 5 The quantity and proportion of biased entities in each model

模型	偏置实体数	识别出实体数	偏置率
CRF	0	2410	0%
BiLSTM-CRF	156	2477	6.29%
BiLSTM-withfea	104	2502	4.15%
Voting	0	2389	0%

3.2.2 实验二 实验中为避免过拟合(Overfitting)问题引入 drop-out^[24],并将参数设置为 0.5。同时引入 l_2 正则化, l_2 -rate 设置为 0.01。

(1) 使用 LSTM-withfea 模型,分别设置 dropout 为 0.5, learning-rate 为 0.001, batch-size 为 128,选择生成词向量的语言模型和向量维度,实验结果见表 6。需要提出的是,选择 Skip-gram 时,窗口长度设置为 10;选择 CBOW 模型时,窗口长度设置为 5;两种模型 min_count 均设置为 3。从表 6 可知, Skip-gram 词向量生成模型在维度为 300 时效果最好,整体上 Skip-gram 模型要优于 CBOW 模型。

(2) 基于 LSTM-withfea 的模型,通过改变神经网络参数训练模型并进行预测,词向量模

表 6 不同词向量生成模型及维度的 F 值(%)

Table 6 The F value of different word vector models and dimensions (%)

模型	维度	
	100	300
Skip-Gram	93.22	93.62
CBOW	92.86	93.04

型选择 300 维的 Skip-gram。选择改变的参数为 learning-rate 和 batch-size,实验结果如表 7 所示,其中, size=64, rate=0.0001 的结果由于内存消耗和进程时间开支过大,实验终止,未能记录。

表 7 不同深度学习参数的 F 值(%)

Table 7 The F value of different parameters in deep learning (%)

learning-rate	batch-size		
	64	128	256
0.01	92.67	92.89	92.73
0.001	93.31	93.62	93.40
0.0001	—	93.41	93.01

从表 7 来看, batch-size 为 128 时 F 值的效果最好,继续增加 batch-size 反而会影响实体识别效果。由以上两个实验可得到 LSTM-withfea 模型的最佳学习参数,见表 8。

表 8 最优深度学习参数(%)

Table 8 The optimal parameters in deep learning (%)

language-model	vector-size	learning-rate	batch-size
Skip-Gram	300	0.001	128

Skip-gram 通过中心词预测周围词,能够更有效地从文本中学习序列信息^[25],可以较好地解决生僻字的学习训练问题,这对中文电子病历实体识别有较大意义。从表 8 可知,在基于 LSTM-withfea 模型的医疗实体识别中,向量的维度为 300 维,学习速率 learning-rate 为 0.001,批处理大小 batch-size 为 128 时,三个参数的组合可以取得最佳实验结果,意味着该参数组合能更好地挖掘序列标签信息。

4 结 论

为了充分挖掘电子病历和医疗问答社区中医疗数据的价值,将更多的实体语义知识融入深度学习算法以提升电子病历中医疗实体的识别效果,本文提出基于深度学习和多特征融合的中文电子病历实体识别模型. 该模型首先利用大规模的未标记电子病历以及医疗问答社区中的文本数据生成字符级向量,接着将医疗实体及特征库转换为向量,并在 BiLSTM 输入层之前将该向量与输入序列的字符级 embedding 相拼接以更好地获取序列信息;最后将该模型和 CRF, BiLSTM-CRF 及改进的 Voting 算法对中文医疗实体识别进行对照实验. 研究发现在中文电子病历实体识别任务中, BiLSTM-withfea 模型的 F 值比 CRF 高 1.55%, 比未加入外部语义特征的 BiLSTM-CRF 模型高 0.65%, 表明根据已有医疗实体语义资源和各类实体结构特征构建的医疗实体及特征库对医疗实体识别提升效果较为明显. 其次, 本文改进的 Voting 算法综合了 CRF 与深度学习算法的优点, 其 F 值虽然略低于 BiLSTM-withfea 模型, 但在其结果中不存在任何标签偏置错误, 实际应用价值更高. 最后还发现, BiLSTM-withfea 中, 词向量生成模型 Skip-Gram 要优于 CBOW; 并且当向量的维度为 300 维, 学习速率 learning-rate 为 0.001 以及批处理大小 batch-size 为 128 时, 三个参数的组合可以取得最佳实验结果. 为进一步验证模型效果, 后续将改进模型, 用于更多科室电子病历的医疗实体识别研究, 还将利用更多医疗数据资源扩充和完善医疗实体及特征库, 以更充分地挖掘实体语义知识, 从而进一步提升中文电子病历实体识别的效果.

参考文献

- [1] Zhu F, Patumcharoenpol P, Zhang C, et al. Biomedical text mining and its applications in cancer research. *Journal of Biomedical Informatics*, 2013, 46(2): 200—211.
- [2] Wang Y S, Wang L W, Rastegar-Mojarad M, et al. Clinical information extraction applications: a literature review. *Journal of Biomedical Informatics*, 2018, 77: 34—49.
- [3] Wu Y H, Jiang M, Lei J B, et al. Named entity recognition in Chinese clinical text using deep neural network. *Studies in Health Technology and Informatics*, 2015, 216: 624—628.
- [4] Segura-Bedmar I, Suárez-Paniagua V, Martínez P. Exploring word embedding for drug name recognition//International Workshop on Health Text Mining and Information Analysis. Lisbon, Portugal: Association for Computational Linguistics, 2015: 64—72.
- [5] 叶枫, 陈莺莺, 周根贵等. 电子病历中命名实体的智能识别. *中国生物医学工程学报*, 2011, 30(2): 256—262. (Ye F, Chen Y Y, Zhou G G, et al. Intelligent recognition of named entity in electronic medical records. *Chinese Journal of Biomedical Engineering*, 2011, 30(2): 256—262.)
- [6] Hu J L, Shi X, Liu Z J, et al. HITSZ_CNER: a hybrid system for entity recognition from Chinese clinical text//China Conference on Knowledge Graph and Semantic Computing 2017. Chendu, China: Springer, 2017, 26—29.
- [7] Keerthi S S, Sundararajan S. CRF versus SVM-struct for sequence labeling. Yahoo Research Technical Report, 2007.
- [8] Jiang M, Chen Y K, Liu M, et al. A study of machine-learning-based approaches to extract clinical entities and their assertions from discharge summaries. *Journal of the American Medical Informatics Association*, 2011, 18(5): 601—606.
- [9] Lei J, Tang B, Lu X, et al. A comprehensive study of named entity recognition in Chinese clinical text. *Journal of the American Medical Informatics Association*, 2013, 21(5): 808—814.
- [10] 王润奇, 关毅. 基于 Tri-Training 算法的中文电子病历实体识别研究. *智能计算机与应用*, 2017, 7(6): 132—134, 138. (Wang R Q, Guan Y. Named entity recognition research in Chinese electronic medical records based on Tri-Training algorithm. *Intelligent Computer and Applications*, 2017, 7(6): 132—134, 138.)

- [11] 付文博,孙涛,梁藉等.深度学习原理及应用综述.计算机科学,2018,45(6A):11–15,40. (Fu W B, Sun T, Liang J, et al. Review of principle and application of deep learning. Computer Science, 2018, 45(6A): 11–15, 40.)
- [12] Lample G, Ballesteros M, Subramanian S, et al. Neural architectures for named entity recognition. arXiv:1603.01360, 2016:260–270.
- [13] Liu Z J, Yang M, Wang X L, et al. Entity recognition from clinical texts via recurrent neural network. BMC Medical Informatics and Decision Making, 2017, 17(2):67.
- [14] Ma X Z, Hovy E. End-to-end sequence labeling via bi-directional lstm - cnns - crf. 2016, arXiv: 1603.01354.
- [15] Chalapathy R, Borzeshi E Z, Piccardi M. Bidirectional LSTM - CRF for clinical concept extraction. 2016, arXiv: 1610.05858.
- [16] Wu J H, Hu X, Zhao R S, et al. Clinical named entity recognition via bi-directional LSTM-CRF model//China Conference on Knowledge Graph and Semantic Computing 2017. Chendu, Sichuan, 2017, 26–29.
- [17] Mikolov T, Kombrink S, Burget L, et al. Extensions of recurrent neural network language model//IEEE International Conference on Acoustics, Speech and Signal Processing. Prague, Czech Republic; IEEE, 2011: 5528–5531.
- [18] Hochreiter S. The vanishing gradient problem during learning recurrent neural nets and problem solutions. International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems, 1998, 6 (2):107–116.
- [19] Donahue J, Hendricks L A, Rohrbach M, et al. Long-term recurrent convolutional networks for visual recognition and description. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2017, 39(4):677–691.
- [20] Gers F A, Schmidhuber J, Cummins F. Learning to forget: continual prediction with LSTM. Neural Computation, 2014, 12(10):2451–2471.
- [21] Habibi M, Weber L, Neves M, et al. Deep learning with word embeddings improves biomedical named entity recognition. Bioinformatics, 2017, 33(14):i37–i48.
- [22] Lafferty J D, Mccallum A, Pereira F C N. Conditional random fields: Probabilistic models for segmenting and labeling sequence data// Proceedings of the 18th International Conference on Machine Learning. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc., 2001: 282–289.
- [23] Goldberg Y, Levy O. word2vec Explained: Deriving Mikolov et al.'s negative-sampling word-embedding method. 2014, arXiv: 1402.3722.
- [24] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting. The Journal of Machine Learning Research, 2014, 15(1):1929–1958.
- [25] Mikolov T, Chen K, Corrado G, et al. Efficient estimation of word representations in vector space. 2013, arXiv: 1301.3781.

(责任编辑 杨可盛)