

融合语义及边界信息的中文电子病历命名实体识别



崔少国*, 陈俊桦, 李晓虹

(重庆师范大学计算机与信息科学学院 重庆 沙坪坝区 401331)

【摘要】中文电子病历数据专业性强,语法结构复杂,用于自然语言处理(NLP)的命名实体识别(NER)难度大。为了从电子病历数据中精确识别出医疗实体,提出了一种融合语义及边界信息的命名实体识别算法。首先,利用卷积神经网络(CNN)结构提取汉字图形信息,并与五笔特征拼接来丰富汉字的语义信息;然后,利用FLAT模型中的Lattice将医学词典作为字符潜在词组匹配文本信息;最后,将融入语义信息的Lattice模型用于中文电子病历命名实体识别。实验结果表明,该方法在Yidu-S4K数据集上的识别性能超过现有多种算法,且在Resume数据集上F1值可达到96.06%。

关键词 中文电子病历; FLAT; 医学字典; 命名实体识别; 自然语言处理

中图分类号 TP391.1

文献标志码 A

doi:10.12178/1001-0548.2021350

Named Entity Recognition for Chinese Electronic Medical Record by Fusing Semantic and Boundary Information

CUI Shaoguo*, CHEN Junhua, and LI Xiaohong

(College of Computer and Information Science, Chongqing Normal University Shapingba Chongqing 401331)

Abstract Chinese electronic medical record texts are highly professional, with complex grammar, it is difficult to use named entity recognition (NER) for natural language processing (NLP). In order to accurately identify medical entities from electronic medical record data, a named entity recognition algorithm combining semantic and boundary information is proposed. In this algorithm, the graphic information of Chinese characters is extracted by using the convolutional neural network (CNN) structure and the semantic information of the Chinese characters is enriched with Wubi features. And then the text information is matched with medical dictionary as a potential phrase of characters by using the Lattice in the FLAT model. Finally, the Lattice model incorporating semantic information is used for named entity recognition in Chinese electronic medical records. The experimental results show that this method has better recognition performance than other existing methods on the Yidu-S4K data set, and the F1 value on the Resume dataset is 96.06%.

Key words Chinese electronic medical record; FLAT; medical dictionary; named entity recognition (NER); natural language processing (NLP)

随着医院信息系统的快速发展与应用,医疗机构中积累了大规模的电子病历数据。这些数据是病人在医院就诊及治疗过程中所产生的重要记录,包含病历文本、医学图表、医学影像等多种类型数据。其中,非结构化形式的电子病历文本数据是最主要的部分,如主诉、诊断结果、入院/出院记录和治疗过程等,这些数据蕴含着大量有价值的医疗知识及健康信息^[1]。从非结构化文本中识别出与医

疗相关的实体名称,并将它们归类到预定义类别,如疾病、治疗、症状、药品等,是电子病历数据挖掘与信息抽取的关键步骤,这一任务称为电子病历命名实体识别(named entity recognition, NER)^[2]。它不仅是自然语言处理(natural language processing, NLP)相关任务,如信息检索、信息抽取以及问答系统等的重要基础工作^[3],同时对电子病历的应用如合并症分析、不良药物事件检测以及药物相互作用分析

收稿日期: 2021-11-30; 修回日期: 2022-01-19

基金项目: 重庆市科技局项目(cstc2018jcyjAX0324, cstc2019jcsx-mbdcX0061); 重庆市教委科技项目(KJQN201800539, KJQN202000510); 重庆市研究生科研创新项目(CYS22565); 教育部人文社科项目(18XJC880002)

作者简介: 崔少国(1974-), 男, 博士, 教授, 主要从事大数据与人工智能等方面的研究。

*通信作者: 崔少国, E-mail: csg@cnu.edu.cn

等起到了巨大的推动作用。

近年来,针对英文电子病历的命名实体识别问题,学者们已经提出了几种有效的神经网络算法模型。其中,双向长短记忆 (bidirectional long short memory, BiLSTM) 与条件随机场 (conditional random field, CRF) 的组合^[4-6]以及卷积神经网络 (convolutional neural network, CNN) 与条件随机场的组合模型^[7-8]最为流行。

与英文电子病历的命名实体识别相比,中文电子病历的命名实体识别问题更具有挑战性。主要原因是医学文本经常使用不规范的缩写,并且大多数实体有多种书写形式。目前大多数中文电子病历的命名实体识别方法主要是基于字的 BiLSTM-CRF 和 CNN-CRF 算法模型,并利用汉字和医学词典等特征,来提升识别的性能^[9-11]。但是,由于循环神经网络 (recurrent neural network, RNN) 无法并行计算,当句子中的某个字符与词典中的多个词组有关时, RNN 模型通常难以做出判断。如 Lattice LSTM^[12] 使用了跨输入长度的双重递归过渡计算,一个用于句子中的所有字符,另一个用于词典中匹配的潜在单词,因此其计算速度有限。除此之外,这类模型很难处理字典中潜在单词之间的冲突:如果一个字符对应字典中成对的潜在单词,这种冲突可能会误导模型,使其预测不同的标签。如“重庆市长安药店”,文本中的“长”可能属于“市长”一词,也可能属于“长安”一词,对“长”所属词组判别的不同,将导致对字符“长”预测的标签不同。而 flat-Lattice transformer for Chinese NER

(FLAT)^[13] 模型,采用全连接自注意力结构,字符可以直接与其所匹配词汇进行交互,同时捕捉长距离依赖,不但可以提高并行计算效率,还能很好地避免潜在单词之间的冲突问题。

在命名实体识别任务中有一种增强识别能力的方法叫做自适应嵌入范式。该方法仅在嵌入层对词汇信息进行自适应调整,后面通常接入 LSTM+CRF 或其他通用网络,这种范式与模型无关,具备可迁移性。如 WC-LSTM^[14],采取单词编码策略,将每个字符为结尾的词汇信息进行固定编码表示,每一个字符引入的词汇表征是静态的、固定的,如果没有对应的词汇则用 <PAD> 代替,因此可以进行批量并行化。文献 [15] 第一次研究了部首级别信息在中文 NER 的应用,使用 Bi-LSTM 来提取部首层面的嵌入,然后将其与字符嵌入连接起来作为最终输入。文献 [16] 利用汉字图像提取汉字的笔画、结构等特征,取得了较好的性能。

在以上研究的基础上,本文将汉字图像特征、五笔字型编码进行融合,然后将其作为高级语义信息,与依据字符及潜在医学词组生成的相对位置编码融合,采用 FLAT 的 Lattice 模型架构实现中文电子病历的命名实体识别。

1 方 法

本文提出了一种新的算法模型 WHSemantic+Lattice,其结构框架如图 1 所示。算法将汉字图像特征、五笔字型编码进行融合作为高级语义信息,再融入包含潜在医学词组的 FLAT 模型的 Lattice 中,最后通过条件随机场输出标记结果。




图 1 WHSemantic+Lattice 结构

1.1 FLAT 模型

受到位置向量表征的启发, FLAT 模型设计了一种巧妙的位置编码来融合 Lattice 结构。如图 2 所示,对于每一个字符和词汇都构建两个头位置编码和尾位置编码,这种方式可以重构原有的 Lattice

结构。也正因如此, FLAT 可实现该字符与其所有匹配信息词汇之间的交互,如字符[药]可以匹配词汇[长安药店]和[药店]。

基于 Lattice 结构的嵌入层是将自然语言文本转为计算机能够识别的向量表示,而词向量

ctb.50d.vec 是基于 CTB 6.0(Chinese treebank 6.0) 语料库训练得到的。鉴于医学词组的专业性强、语法结构复杂, 为了提高模型对中文电子病历实体识别能力, 本文收集了全国知识图谱与语义计算大会 (CCKS: China Conference on Knowledge Graph and Semantic Computing) 近几年与医学相关的比赛数据集, 并将数据集中提到的医学词组作为医学

词汇表保存下来, 表中包含近 3 万个医学词组。在获取 ctb.50d.vec 中的所有词汇信息并保存为列表以后, 再将医学词汇表中 ctb.50d.vec 不包含的词组增加到列表中组成潜在词表, 从而在 Lattice 中嵌入层输入字符匹配词表中的潜在单词时, 可以匹配到更多的医学词组, 提高汉字水平的中文医学内隐能力。




图2 Flat-Lattice 结构

图2 为 FLAT 的输入和输出, 使用头部 (head) 和尾部 (tail) 位置转换的相对位置编码来拟合单词的边界信息。相对位置编码 R_{ij} 计算如下:

$$R_{ij} = \text{ReLU}(W_r(p_{d_{ij}^{(hh)}} \oplus p_{d_{ij}^{(th)}} \oplus p_{d_{ij}^{(ht)}} \oplus p_{d_{ij}^{(tt)}})) \quad (1)$$

式中, W_r 为学习参数; 4 种相对距离 d_{ij}^* 表示输入 x_i 和 x_j 之间的关系, 同时也考虑字符和词汇之间的关系, 其表示如下:

$$d_{ij}^{(hh)} = \text{head}[i] - \text{head}[j] \quad (2)$$

$$d_{ij}^{(ht)} = \text{head}[i] - \text{tail}[j] \quad (3)$$

$$d_{ij}^{(th)} = \text{tail}[i] - \text{head}[j] \quad (4)$$

$$d_{ij}^{(tt)} = \text{tail}[i] - \text{tail}[j] \quad (5)$$

而 p_d 的计算方式与文献 [17] 相同:

$$p_d^{(2k)} = \sin\left(\frac{d}{10000^{2k/d_{\text{model}}}}\right) \quad (6)$$

$$p_d^{(2k+1)} = \cos\left(\frac{d}{10000^{2k/d_{\text{model}}}}\right) \quad (7)$$

然后得到缩放的点积注意力:

$$\text{Att}(A, V) = \text{softmax}(A)V \quad (8)$$

$$A_{ij} = (Q_i + \mu)^T K_j + (Q_i + \nu)^T R_{ij}^* \quad (9)$$

$$[Q, K, V] = E_x[W_q, W_k, W_v] \quad (10)$$

式中, $R_{ij}^* = R_{ij} W_R$; μ, ν 和 W_q, W_k, W_v 是对应的权重

矩阵。

1.2 HSemantic 模型

汉字是以象形文字为基础的, 其含义用物体的形状来表达, 因此汉字的结构对 NER 有一定的改善信息。如部首“艹”(草)和“木”(木)一般代表植物, 可以增强中医命名实体识别; “月”(身体)代表人体部分或器官, “疒”(疾病)代表疾病, 这有利于中文电子病历命名实体识别。本文考虑将汉字的图像特征通过 CNN 提取出来, 象形信息在简体中文中大量丢失。因此, 本文尝试了不同的文字图形, 最后发现基于 NotoSansCJKsc-Regular 的文字效果最好, 于是将基于 NotoSansCJKsc-Regular 的汉字输入图像。

Noto 是 Google 一直在开发的一种字体系列, 旨在以和谐的外观支持所有语言, 具有多种样式和权重。NotoSansCJKsc 为简体中文, 其包含 7 种款式, 9 种语言, 4 个地区, 通过字体百科网站 (<https://www.zitibaike.com>) 可下载该字体。

本文通过 Python 的图像处理库 ImageFont 中的 TrueType 函数创建 NotoSansCJKsc 字体对象, 再基于每一个字符调用 getmask 生成对应的位图, 并利用 numpy 中的 asarray 函数将位图转为特征矩阵, 最后通过 HSemantic 模型提取汉字图像的结构特征。

图3 为 HSemantic 模型结构, 首先通过内核大小为 5 输出通道为 64 的卷积层, 以捕获较低级别的图形特征。然后, 将其送到 2×2 的最大池化中,

将分辨率从 15×15 降低到 2×2 , 形成类似田字格的形状, 田字格是一种传统的中国书法形式, 展示了部首在汉字中的排列方式以及汉字的书写顺序, 能

够更好地显示汉字图像的结构特征。最后, 应用文献 [18] 的组卷积运算将网格映射到最终输出, 因为组卷积不容易过拟合。




图 3 HSemantic 结构

1.3 WHSemantic+Lattice 模型

通过 Python 的汉字五笔转换工具库 pywubi 中的 wubi 函数, 根据输入字符, 找到其对应的五笔编码, 再通过五笔编码在五笔解码库中找到对应的解码。如字符[中]的五笔编码为 [k,h,k], 对应解码 id 为 [35,32,35]。最后, 将经过解码后的五笔传到 LSTM 中来增强五笔编码间的特征联系, 作为字符的笔画特征表示向量。

在文字图像及五笔字型特征提取后, 将它们通过全连接层连接起来, 作为汉字的语义特征, 再将其与 FLAT 结构的字符部分拼接起来作为嵌入层的输入:

$$E = E_L \oplus E_S \quad (11)$$

式中, E 表示 Lattice 嵌入层和汉字图形及笔画特征的嵌入层拼接; E_L 表示 Lattice 的嵌入层; E_S 表示汉字图形及笔画特征的嵌入层, 其中 E_S 对应 Lattice 的潜在单词部分用 0 补齐, 从而不会对潜在单词部分造成影响。

将 E 通过 Lattice 的线性变换:

$$\begin{bmatrix} Q_i \\ K_i \\ V_i \end{bmatrix}^T = E_i \begin{bmatrix} W_Q \\ I \\ W_V \end{bmatrix}^T \quad (12)$$

式中, I 是单位矩阵; W_Q 和 W_V 是权重矩阵。然后使用 FLAT 中的位置编码来表示单词的边界信息, 并计算注意力得分:

$$A = (Q_i + u)^T K_j + (Q_i + v)^T R_{ij}^* \quad (13)$$

$$\text{Att}(A, V) = \text{Softmax}(A)V \quad (14)$$

式中, u 和 v 表示学习参数; A 表示注意力得分;

$R_{ij}^* = R_{ij} W_R$, 相对位置编码 R_{ij} 计算公式为:

$$R_{ij} = \text{ReLU}(W_r(p_{d_{ij}}^{(hh)} \oplus p_{d_{ij}}^{(th)} \oplus p_{d_{ij}}^{(ht)} \oplus p_{d_{ij}}^{(tt)})) \quad (15)$$

在获得 FLAT 层的最终输出后, 屏蔽其他部分, 只将字符表示带入输出层, 送到文献 [19] 的条件随机场中计算最终结果。

2 实验

2.1 数据集

本实验使用的电子病历数据集是医渡云 (北京) 技术有限公司用于医疗命名实体识别评测任务的 Yidu-S4K, 其包含: 疾病和诊断、检查、检验、手术、药物、解剖部位 6 个实体类型, 采用 BIOES 标注体系统一进行标注。在 BIOES 标注体系中, B 代表实体的开始位置, I 代表实体的内部, O 代表非实体部分, E 代表实体的结尾, S 代表单独组成一个实体部分。本文将 subtask1_training_part1 和 subtask1_training_part2 部分的训练数据合并在一起, 并随机打乱后, 按照 7:3 的比例划分训练集和验证集。表 1 显示了该数据集的分布情况。

表 1 Yidu-S4K 中文电子病历数据集情况

类型	subtask1_ training_part1	subtask1_ training_part2	总计
疾病和诊断	1747	2465	4212
手术	417	612	1029
解剖部位	3604	4822	8426
药物	838	984	1822
影像检查	223	746	969
实验室检验	513	682	1195
实体数	7342	10311	17653

为了验证模型的泛化能力,使用 Resume 数据集^[13]。这是一份简历数据集,包含中国股市上市公司高管的简历。Resume 数据集采用 BMESO 标注体系统一进行标注, BMESO 标注体系中, B 代表实体的开始位置, M 代表实体的内部, E 代表实体的结尾, S 代表单独组成一个实体, O 代表非实体部分。表 2 显示了该数据集的统计情况。

表 2 Resume 数据集情况 $\times 10^3$

类型	训练集	验证集	测试集
句子/条	3.8	0.46	0.48
字符/个	124.1	13.9	15.1

2.2 实验设置

实验采用 python 3.8, pytorch 1.7.0 和 fastNLP 0.6.0 框架, 并使用 NVIDIA 显卡 GTX3080Ti 进行加速, 优化器采用 sgd+moment 梯度下降算法进行参数优化。

本文使用准确率 (Precision), 召回率 (Recall) 和 F1 值来评价模型的识别效果, 其中 F1 值可用来评价模型的综合性能。

2.3 对比实验

为了验证本文方法的性能, 设计了对比实验, 包括与其他算法模型的对比及新算法自身的消融实验。

1) BiLSTM-CRF 模型^[20]。该模型应用于序列标注任务。将句子的词向量表示输入该模型并对句子的标注序列进行预测。与文献 [20] 不同, 为了应对词语边界模糊的问题, 本文以字为单位构建字向量。

2) BiLSTM+Attention+CRF 模型^[21]。该模型在 BiLSTM 层和 CRF 层之间加入了注意力机制。

3) Lattice LSTM+CRF 模型^[12]。该模型将字符的潜在单词一起进行编码, 利用了单词和单词序列信息。

4) LR-CNN 模型^[22]。该模型在 CNN 中加入了 rethink 机制。

另外, 为了验证文字图像特征提取时最大池化对识别效果的影响, 同时验证五笔特征 (WSemantic+Lattice)、文字图像 (HSemantic+Lattice) 信息以及 WHSemantic+Lattice 对识别效果的影响, 本文进行了消融实验。

3 结果及分析

针对 Yidu-S4K 中文电子病历数据集, 本文从

准确率、召回率和 F1 值 3 个性能指标方面对各种算法进行了对比。实验结果如表 3 所示。

表 3 Yidu-S4K 中文电子病历数据集的实验结果

模型	准确率	召回率	F1值
BiLSTM-CRF	69.43	72.58	71.97
BiLSTM-Attention CRF	65.96	50.24	57.04
Lattice-LSTM	70.19	72.34	71.25
LR-CNN	57.77	50.29	53.77
FLAT	73.76	72.51	73.13
WHSemantic+Lattice	76.21	74.56	75.37

从实验结果可以看出, Lattice 结构模型使算法的性能指标均得到提高, 说明边界信息可以为电子病历实体识别提供参考的位置信息, 以确保算法的识别性能; 而当模型在边界信息的基础上融合了单词的语义信息后, 模型整体识别性能进一步提升, 本文算法在各项性能指标上均取得了最优值, F1 值从 73.13% 提升到 75.37%。可见, 边界与语义信息的融合有效提升了电子病历命名实体识别精度。

针对 Resume 数据集, 本文使用提出的算法实现了命名实体识别, 并将实验结果与其他模型进行了对比, 结果如表 4 所示。

表 4 Resume 数据集上实验结果

模型	准确率	召回率	F1值
Word+char+biLSTM ^[12]	93.72	93.44	93.58
Lattice-LSTM ^[12]	94.81	94.11	94.46
LR-CNN ^[22]	95.37	94.84	95.11
FLAT ^[13]	-	-	95.45
WHSemantic+Lattice	95.68	96.44	96.06

从表 4 可以看出, 使用 Lattice 可以使 F1 值显著提高, 而使用语义信息的 WHSemantic+Lattice 模型比 FLAT 模型的 F1 值提升了 0.61%。这是因为 FLAT 的 Lattice 更加关注词与字符之间的关系, 从而可以获得词的位置信息和边界信息。WHSemantic 关注点集中在全局信息上, 通过笔画特征修正每个字的语义信息。因此, FLAT 的 Lattice 关注点和 WHSemantic 关注点为本文方法在中文命名实体识别中的性能提升提供了补充信息。

针对消融实验 (1) 和实验 (2), 分别在 FLAT 的 Lattice 中加入实验 (1) 的处理方法, 即处理汉字图像提取时分别使用 8×8 、 4×4 、 2×2 的最大池化层和不使用池化层的 WHSemantic 模型; 另加入实

验 (2) 的处理方法, 即 WSemantic 或 HSemantic。并在 Yidu-S4K 中文电子病历数据集测试其效果。

表 5 和表 6 分别显示了实验 (1)、实验 (2) 各自的对比结果。

表 5 消融实验 (1) 的实验结果

最大池化层	准确率	召回率	F1值
无	72.27	67.24	69.67
8×8	75.78	73.22	74.48
4×4	67.51	65.09	66.28
2×2	76.21	74.56	75.37

表 6 消融实验 (2) 的实验结果

模型	准确率	召回率	F1值
FLAT-Lattice	73.76	72.51	73.13
HSemantic+ Lattice	74.62	72.61	73.60
WSemantic+ Lattice	75.02	73.24	74.11
WHSemantic+Lattice	76.21	74.56	75.37

从表 5 的结果来看, 恰当地使用最大池化层可

以有效提高汉字图像特征, 使识别效果得到进一步提升。但并不是所有最大池化层都可以提升模型的效果, 如果使用不恰当的最大池化层, 反而会使模型的识别效果变差, 如当使用 4×4 的最大池化层时, F1 值比不使用最大池化层低了 3.39%。并且通过不同最大池化层对比, 发现基于 2×2(类似于田字格) 的最大池化层较适合提取汉字图像特征。

从表 6 可以看出, 使用五笔字型特征可以显著提升模型的精度, 是因为相同类型的实体部分偏旁信息也可能是相似的, 而文字图像信息可以进一步提升语义信息, 从而有效提高模型的识别能力。

汉字特征对于中文电子病历命名实体识别任务非常有用, 因为它可以提供丰富的语义信息。为了验证本文模型可以更好地利用边界及语义信息, 本文分析了 Yidu-S4K 中文电子病历数据集中的一个示例。如表 7 所示 (DD 为疾病和诊断缩写), 与 Lattice 模型不同, 本文模型没有遗漏任何重要的信息, 且与标准划分具有一样的医学含义。

表 7 应用效果示例对比

句子	标准划分	Lattice-LSTM	FLAT	WHSemantic+Lattice
两肺感染及右侧基节及侧脑室体旁小腔隙灶	两(B-DD)	两(O)	两(O)	两(B-DD)
	肺(I-DD)	肺(B-DD)	肺(B-DD)	肺(I-DD)
	感(I-DD)	感(I-DD)	感(I-DD)	感(I-DD)
	染(I-DD)	染(E-DD)	染(E-DD)	染(E-DD)
	及(I-DD)	及(O)	及(O)	及(O)
	右(I-DD)	右(B-DD)	右(B-DD)	右(B-DD)
	侧(I-DD)	侧(I-DD)	侧(I-DD)	侧(I-DD)
	基(I-DD)	基(I-DD)	基(I-DD)	基(I-DD)
	节(I-DD)	节(E-DD)	节(E-DD)	节(E-DD)
	及(I-DD)	及(O)	及(O)	及(O)
	侧(I-DD)	侧(B-DD)	侧(B-DD)	侧(B-DD)
	脑(I-DD)	脑(I-DD)	脑(I-DD)	脑(I-DD)
	室(I-DD)	室(E-DD)	室(E-DD)	室(I-DD)
	体(I-DD)	体(O)	体(O)	体(I-DD)
	旁(I-DD)	旁(O)	旁(O)	旁(I-DD)
	小(I-DD)	小(O)	小(O)	小(I-DD)
	腔(I-DD)	腔(O)	腔(O)	腔(I-DD)
	隙(I-DD)	隙(O)	隙(O)	隙(I-DD)
	灶(E-DD)	灶(O)	灶(O)	灶(E-DD)

4 结束语

中文电子病历命名实体识别是医学文本理解的重要基础性工作。本文提出了将汉字图像特征、五笔字型编码作为高级语义信息, 融入包含潜在医学词组的 FLAT 模型的 Lattice 中, 充分利用了语义

及边界特征信息对中文电病历数据进行医学实体命名识别, 并在 Yidu-S4K 数据集上表现出高效的识别性能。但是, 中文电子病历的命名实体识别是一个高度复杂的序列标记任务, 识别效率仍然有较大的提升空间。后期会对模型继续进行优化调整, 将

更多的语言先验知识融入到中文电子病历命名实体识别任务中。

参 考 文 献

- [1] ZHANG J, LI J, WEN Z, et al. Overview of CCKS 2018 task 1: Named entity recognition in Chinese electronic medical records[C]//China Conference on Knowledge Graph and Semantic Computing. Singapore: Springer, 2019: 158-164.
- [2] ZHANG J, LI J, WANG S, et al. Category multi-representation: A unified solution for named entity recognition in clinical texts[C]//Pacific-Asia Conference on Knowledge Discovery and Data Mining. Cham: Springer, 2018: 275-287.
- [3] MEYSTRE S M, SAVOVA G K, KIPPERSCHULER K C, et al. Extracting information from textual documents in the electronic health record: A review of recent research[J]. *Yearbook of Medical Informatics*, 2008, 17(1): 128-144.
- [4] UNANUE I J, BORZESHI E Z, PICCARDI M. Recurrent neural networks with specialized word embeddings for health-domain named-entity recognition[J]. *Journal of Biomedical Informatics*, 2017, 76: 102-109.
- [5] LAMPLE G, BALLESTEROS M, SUBRAMANIAN S, et al. Neural architectures for named entity recognition [C]//Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: ACL, 2016: 260-270.
- [6] ZENG D, SUN C, LIN L, et al. LSTM-CRF for drug-named entity recognition[J]. *Entropy*, 2017, 19(6): 283.
- [7] COLLOBERT R, WESTON J, BOTTOU L, et al. Natural language processing (almost) from scratch[J]. *Journal of Machine Learning Research*, 2011, 12: 2493-2537.
- [8] STRUBELL E, VERGA P, BELANGER D, et al. Fast and accurate entity recognition with iterated dilated convolutions[C]//Conference on Empirical Methods in Natural Language Processing. East Stroudsburg: EMNLP, 2017: 2670-2680.
- [9] QIU J, ZHOU Y, WANG Q, et al. Chinese clinical named entity recognition using residual dilated convolutional neural network with conditional random field[J]. *IEEE Transactions on Nanobioscience*, 2019, 18(3): 306-315.
- [10] WANG Q, ZHOU Y, RUAN T, et al. Incorporating dictionaries into deep neural networks for the Chinese clinical named entity recognition[J]. *Journal of Biomedical Informatics*, 2019, 92: 103133.
- [11] JI B, LIU R, LI S, et al. A BiLSTM-CRF method to Chinese electronic medical record named entity recognition[C]//Proceedings of the 2018 International Conference on Algorithms, Computing and Artificial Intelligence. Sanya: ACAI, 2018: 1-6.
- [12] ZHANG Y, YANG J. Chinese NER using Lattice LSTM[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2018: 1554-1564.
- [13] LI X, YAN H, QIU X, et al. FLAT: Chinese NER using Flat-Lattice transformer[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2020: 6836-6842.
- [14] LIU W, XU T, XU Q, et al. An encoding strategy based word-character LSTM for Chinese NER[C]//Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). Minneapolis: NAACL, 2019: 2379-2389.
- [15] DONG C, ZHANG J, ZONG C, et al. Character-based LSTM-CRF with radical-level features for Chinese named entity recognition[C]//Natural Language Understanding and Intelligent Applications: 5th CCF Conference on Natural Language Processing and Chinese Computing. Kunming: Springer, 2016: 239-250.
- [16] MENG Y, WU W, WANG F, et al. Glyce: Glyph-vectors for Chinese character representations[C]//Proceedings of the 33rd International Conference on Neural Information Processing Systems. San Diego: NIPS, 2019: 2746-2757.
- [17] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems. Corvallis: ACM, 2017: 6000-6010.
- [18] KRIZHEVSKY A, SUTSKEVER I, HINTON G E. ImageNet classification with deep convolutional neural networks[C]//Proceedings of the 25th International Conference on Neural Information Processing Systems-Volume 1. San Diego: NIPS, 2012: 1097-1105.
- [19] LAFFERTY J, MCCALLUM A, PEREIRAS F C N. Conditional random fields: Probabilistic models for segmenting and labeling sequence data[C]//Proc 18th International Conference on Machine Learning. Corvallis: ACM, 2001: 282-289.
- [20] HUANG Z H, XU W, YU K. Bidirectional LSTM-CRF models for sequence tagging[EB/OL]. (2015-08-09). <https://arxiv.org/abs/1508.01991>.
- [21] JIA Y, MA X. Attention in character-Based BiLSTM-CRF for Chinese named entity recognition[C]//Proceedings of the 2019 4th International Conference on Mathematics and Artificial Intelligence. [S.l.]: ICAI, 2019: 1-4.
- [22] GUI T, MA R, ZHANG Q, et al. CNN-Based Chinese NER with Lexicon Rethinking[C]//IJCAI International Joint Conference on Artificial Intelligence. Macao, China: IJCAI, 2019: 4982-4988.

编 辑 刘飞阳